CityVision · Proof of concept · Текст выступления (русский перевод)

Перевод французского текста выступления; номера разделов совпадают с номерами слайдов. Хронометраж указан для выступления на французском. Целевая длительность: 20 минут. План ≈ 4 мин 20, подход и результаты ≈ 9 мин 20, демонстрация и заключение ≈ 5 мин, запас ≈ 1 мин 20. Темп: около 130 слов в минуту.

Часть 1 · План (plan prévisionnel) (≈ 4 мин 20)

1. Сегментировать город с EoMT **0:20**

Здравствуйте, Карим. Я представлю proof of concept, выполненный в проекте CityVision, в три этапа. Сначала план: набор данных, выбранная модель и источники. Затем подход: концепции новой модели и её результаты в сравнении с baseline. И наконец, демонстрация дашборда, развёрнутого в облаке.

Накопленное время: 0:20

2. Отправная точка: 0,816 mIoU **0:50**

CityVision сегментирует уличные фотографии на девять классов: дорога, здание, растительность, небо, человек, автомобиль, дорожный знак, велосипед и класс «фон» для всего остального.

Текущая модель — ResNet50-UNet. Она присваивает класс каждому пикселю и обслуживается API и приложением проекта. На 500 валидационных изображениях она даёт 0,816 mIoU. mIoU — это среднее по девяти классам отношение пересечения к объединению между предсказанием и разметкой.

Вопрос этого proof of concept простой: делает ли недавняя модель, моложе пяти лет, лучше — в точно таких же условиях?

Накопленное время: 1:10

3. Cityscapes, сведённый к 9 классам **1:00**

Набор данных — тот же, что в проекте: Cityscapes. Это фотографии, снятые из автомобиля в немецких городах и размеченные попиксельно. 2 975 обучающих изображений из 18 городов и 500 валидационных из 3 других городов. Мы работаем в разрешении 512 на 1024, то есть в половине исходного.

Главное — дисбаланс. Дорога, фон и здания покрывают три четверти пикселей. Люди, знаки и велосипеды, оранжевым, вместе дают меньше 2 %. Но именно эти объекты критичны для вождения. При этом знаки есть на 94 % изображений: это не редкие объекты, это мелкие объекты.

Поэтому именно на этих мелких классах я жду выигрыша от новой модели.

Накопленное время: 2:10

4. Выбранная модель: EoMT (CVPR 2025) 1:20

Выбранная модель — EoMT, опубликованная в марте 2025 года и представленная на CVPR 2025. Четыре аргумента.

Первый: смена парадигмы. Вместо классификации каждого пикселя модель предсказывает набор масок, каждую со своим классом. Именно этот подход сегодня лидирует в рейтингах сегментации.

Второй: маска покрывает объект целиком. Поэтому ожидается выигрыш на мелких объектах — как раз на слабых классах baseline.

Третий: модель простая и быстрая. EoMT показывает, что достаточно одного Vision Transformer, без декодеров предыдущих моделей. Авторы заявляют точность на уровне state of the art при скорости до четырёх раз выше.

Четвёртый: это реализуемо. Официальный код под лицензией MIT, интегрирован в Hugging Face, есть предобученные веса.

В качестве промежуточного шага был также обучен Mask2Former 2022 года, упрощением которого является EoMT. Это позволяет разделить вклад самой парадигмы масок и вклад EoMT.

Накопленное время: 3:30

5. Три научных источника 0:50

Мои три источника — научные статьи, опубликованные на arXiv.

Статья EoMT, Kerssies и соавторы, 2025: это реализованный алгоритм.

Статья Mask2Former, Cheng и соавторы, 2022: она вводит классификацию масок и masked attention, из которых вырос EoMT.

И статья Cityscapes, Cordts и соавторы, 2016: набор данных и протокол оценки.

С указанием источника переиспользованы код Hugging Face Transformers и рецепт обучения из официального репозитория EoMT. Остальное — собственная работа проекта: девять классов, разрешение, пайплайн данных, оценка и дашборд.

Накопленное время: 4:20

Часть 2 · Подход и результаты (≈ 9 мин 20)

6. Честное сравнение 0:40

Чтобы сравнение было честным, всё, что может быть одинаковым, одинаково: те же изображения, то же разрешение, тот же взвешенный сэмплер для редких классов, тот же бюджет — 20 эпох с ранней остановкой, и та же метрика, посчитанная одним и тем же кодом. Ни одна модель раньше не видела Cityscapes.

Различается то, что является частью каждого метода: предобучение и рецепт из статьи. У моего ноутбучного GPU 8 ГБ: трансформеры обучаются батчами по 2 с накоплением градиента, что даёт тот же эффективный батч 4, что и у baseline.

Накопленное время: 5:00

7. От пикселей к набору масок 0:50

Первая концепция: постановка задачи.

Baseline выдаёт девять карт оценок и для каждого пикселя берёт класс с максимальной оценкой. Это больше полумиллиона независимых решений на изображение.

Mask2Former и EoMT предсказывают фиксированный набор из N пар: 100 у Mask2Former, 200 у EoMT. Каждая пара — это вектор вероятностей классов, включая класс «нет объекта», и маска. Чтобы вернуться к попиксельной карте, для каждого класса суммируются маски, взвешенные его вероятностью, и берётся максимум.

Со стороны данных каждая разметка превращается в набор бинарных масок, по одной на присутствующий класс. Вот восемь масок одного валидационного изображения.

Накопленное время: 5:50

8. Венгерское сопоставление, затем функция потерь 0:50

Вторая концепция: как обучать набор, если порядок запросов произволен? Через сопоставление.

Для каждого изображения считается стоимость сопоставления каждой реальной маски каждому запросу: вероятность правильного класса плюс ошибка маски. Венгерский алгоритм находит сопоставление с минимальной суммарной стоимостью. В примере запрос 2 берёт дорогу, 5 — автомобиль, 1 — человека. Остальные должны предсказывать «нет объекта».

Затем на этом сопоставлении считается функция потерь с весами из статьи: 2 для класса, 5 для бинарной кросс-энтропии и 5 для Dice. И она применяется на каждом промежуточном шаге: это глубокий надзор (deep supervision).

Накопленное время: 6:40

9. Masked attention 0:40

Третья концепция, специфичная для Mask2Former: masked attention.

В классическом внимании каждый запрос смотрит на всё изображение. Здесь к вниманию добавляется маска: ноль там, где маска, предсказанная на предыдущем слое, больше 0,5, и минус бесконечность в остальных местах. После softmax запрос смотрит только на свою зону, оранжевую на схеме. Маска уточняется от слоя к слою, и обучение сходится быстрее.

Вокруг этого Mask2Former строит три блока: backbone Swin, pixel decoder и декодер из девяти слоёв. Это точно, но тяжело.

Накопленное время: 7:20

10. Только ViT-энкодер, без декодера 0:50

Четвёртая концепция: EoMT убирает всё, что Mask2Former добавляет вокруг backbone.

Изображение режется на 2 048 патчей по 16 пикселей и проходит через ViT-B, предобученный с DINOv2. Перед десятым блоком добавляются 200 запросов. В трёх последних блоках запросы и патчи смешиваются обычным self-attention. Затем небольшой модуль выдаёт класс и маску

для каждого запроса.

Модель быстрее по двум причинам: она использует только операции ViT, хорошо оптимизированные в половинной точности, и на инференсе не вычисляет никаких промежуточных масок.

Одна адаптация сделана специально для проекта: предобученная модель ожидает квадратные изображения 640 пикселей. Её position embeddings интерполированы на нашу сетку 32 на 64.

Накопленное время: 8:10

11. Mask annealing: снятие масок **0:40**

Пятая концепция, именно она делает EoMT быстрым: mask annealing.

В начале обучения три последних блока используют masked attention, которое помогает учиться. Затем, блок за блоком, вероятность её применения снижается от 1 до 0. На моих 20 эпохах блок 10 теряет её между эпохами 4 и 8, блок 11 — между 8 и 12, блок 12 — между 12 и 16. Последние четыре эпохи полностью без масок.

Валидация на каждой эпохе шла вообще без масок, ровно как в продакшене. И mIoU продолжала расти во время снятия масок: с 0,835 до 0,842.

Накопленное время: 8:50

12. Рецепт обучения **0:30**

Таблица сводит рецепты. Каждая модель сохраняет рецепт своей статьи, чтобы не оказаться в невыгодном положении.

Два момента по EoMT. Скорость обучения уменьшается по слоям, с множителем 0,8 на блок: первые слои, уже хорошо предобученные, меняются мало. И разогрев (warm-up) идёт в два этапа: сначала головы при замороженном ViT, потом сам ViT.

Накопленное время: 9:20

13. EoMT: +0,027 mIoU **0:45**

Главный результат. На 500 валидационных изображениях baseline получает 0,816 mIoU, Mask2Former 0,842, а EoMT 0,843.

Оба новых метода выигрывают около 2,7 пункта. Чтобы оценить, что это значит, надо смотреть на оставшуюся ошибку, единица минус mIoU. У baseline остаётся 0,184 ошибки, у EoMT 0,157. То есть EoMT убирает 15 % оставшейся ошибки. А на трудных классах больше: 29 % на фоне.

На таком уровне это существенно: baseline уже была отобрана среди пяти CNN-архитектур.

Накопленное время: 10:05

14. Выигрыш на трудных классах **0:40**

Детализация по классам подтверждает гипотезу плана. Самый заметный выигрыш на фоне, который объединяет очень разнородные элементы: плюс 0,071. Затем на людях: плюс 0,042. И на знаках и велосипедах: плюс 0,027. Это классы, на которых baseline была слабой.

Восемь классов из девяти растут. Единственное снижение — небо, большая простая зона,

которая уже обрабатывалась очень хорошо. Также видно, что Mask2Former немного лучше EoMT на знаках.

Накопленное время: 10:45

15. Та же точность, в 2,4 раза быстрее 0:35

По скорости, на моём GPU в половинной точности: 19 миллисекунд на изображение у baseline, 106 у Mask2Former, 43 у EoMT.

EoMT достигает точности Mask2Former, работая в 2,4 раза быстрее. Это подтверждает аргумент статьи на другом наборе данных и другом разрешении.

Две оговорки. Baseline остаётся вдвое быстрее EoMT. А на CPU, как в бесплатном дашборде, преимущество исчезает: оно опирается на тензорные ядра GPU.

Накопленное время: 11:20

16. Реальные и воспроизводимые различия 0:40

Две проверки надёжности.

Слева — парный бутстреп: валидационные изображения пересэмплируются 2 000 раз, и каждый раз разница пересчитывается. 95-процентный интервал разницы с baseline полностью положительный, и для Mask2Former, и для EoMT: выигрыш не зависит от выбора изображений. Между EoMT и Mask2Former интервал содержит ноль: по точности это ничья.

Справа — воспроизводимость: все три модели переобучены с нуля в сданном ноутбуке. Результаты отличаются от эталонных обучений меньше чем на 0,002.

Накопленное время: 12:00

17. Чётче контуры, меньше шума 0:25

Три примера из ноутбука. На первом изображении baseline даёт паразитные пятна фона у края дороги; оба трансформера дают более чистые контуры. На отдельном изображении порядок моделей может меняться: поэтому выводы опираются на все 500 изображений и на бутстреп.

Накопленное время: 12:25

18. Ограничения метода, пути улучшения 0:45

Ограничения самого метода.

EoMT убирает декодер и целиком опирается на ViT, предобученный в большом масштабе. Без такой отправной точки компенсировать нечем. Модель тяжёлая: 94 миллиона параметров против 41 у baseline. Внимание квадратично: в полном разрешении патчей было бы в четыре раза больше, а вычислений внимания — примерно в шестнадцать раз. Скорость есть только на GPU. И мелкие объекты остаются самыми слабыми; на знаках, предположительно, сказывается предобучение на COCO, но это гипотеза.

Пути улучшения: прежде всего исходное разрешение, главный рычаг для мелких объектов. Предварительный тест с Mask2Former, обученным на Cityscapes, дал рост с 0,708 до 0,742 на десяти изображениях. Далее — аугментация данных из статьи, более долгое обучение,

более крупный ViT. И, без переобучения, аугментация во время теста.

Накопленное время: 13:10

19. Ограничения исследования и дальнейшие шаги 0:30

Ограничения исследования. Валидация используется и для выбора лучшей эпохи, и для измерения: оценки немного оптимистичны, но одинаково для всех трёх моделей. Ни у одной модели нет аугментации данных, и наблюдается умеренное переобучение. Предобученные отправные точки различаются — это неотъемлемая часть каждого метода.

Дальнейшие шаги: несколько обучений на модель, чтобы измерить разброс; отдавать EoMT через API на машине с GPU; квантизовать модель для CPU; оценить её на официальном тестовом наборе.

Накопленное время: 13:40

Часть 3 · Демонстрация и заключение (≈ 5 мин)

20. Дашборд, развёрнутый в облаке 4:30 (вживую)

Перед выступлением: открыть дашборд за несколько минут, чтобы «разбудить» его (бесплатный Space). Держать скриншот этого слайда как запасной вариант на случай проблем с сетью.

Теперь перейду к дашборду. Он написан на Streamlit и развёрнут в Space на Hugging Face, все три модели работают на CPU. В нём три страницы.

Страница Dataset (≈ 1 мин 15). Здесь разведочный анализ набора данных: число изображений по городам и доля каждого класса. *(Выбрать «bicycle» в галерее.)* Галерея показывает примеры по классам: вот велосипеды, часто маленькие и частично закрытые. *(Выбрать CLAHE, подвигать ползунок.)* Можно также применить преобразование, например адаптивное выравнивание CLAHE, и сравнить гистограмму до и после.

Страница Prediction (≈ 2 мин). *(Выбрать изображение, модель EoMT, нажать Predict.)* Выбираю валидационное изображение и модель EoMT. Вот предсказанная маска рядом с настоящей и таблица оценок по классам для этого изображения. *(Включить «Compare all models».)* При включённом сравнении все три модели работают на одном изображении. На CPU это занимает около десяти секунд. *(Во время ожидания:)* как мы видели, без GPU преимущество EoMT в скорости исчезает. *(Когда результат появился:)* видны паразитные пятна baseline и более чистые контуры трансформеров.

Страница Model comparison (≈ 45 с). И наконец сводка: график «точность против скорости» и интервалы бутстрепа.

Доступность (≈ 30 с). Дашборд следует критериям WCAG: у каждого изображения есть альтернативный текст, каждый график продублирован таблицей, цвета различимы для людей с нарушением цветового зрения, всё управляется с клавиатуры.

Накопленное время: 18:10

21. Заключение 0:30

В заключение. EoMT, модель 2025 года, превосходит baseline на 2,7 пункта mIoU, статистически значимо: на 15 % меньше оставшейся ошибки и ещё больше на трудных классах. По точности она равна Mask2Former, при этом в 2,4 раза быстрее на GPU.

Моя рекомендация: взять EoMT в следующую версию CityVision, отдавать её на GPU, с аугментацией данных и в исходном разрешении.

Спасибо. Жду ваших вопросов.

Накопленное время: 18:40 · запас ≈ 1 мин 20

Вероятные вопросы и варианты ответов

Не слишком ли мал выигрыш 0,027? На уровне 0,82 mIoU каждый пункт даётся дорого. EoMT убирает 15 % оставшейся ошибки, 29 % на фоне, и бутстреп показывает, что выигрыш всегда положительный (95-процентный интервал: от 0,022 до 0,032).

Почему EoMT, а не Mask2Former, раз они наравне? Та же точность, но в 2,4 раза быстрее на GPU (43 мс против 106 мс) и более простая архитектура: один ViT, без декодера.

Честно ли сравнение при разном предобучении? Всё, что могло быть одинаковым, одинаково: данные, разрешение, сэмплер, бюджет, метрика, код оценки. Ни одна модель не видела Cityscapes. Предобучение — часть каждого метода.

Почему нет аугментации данных? Чтобы все три модели сравнивались в тех же условиях, что и существующая baseline, у которой её не было. Это первое предлагаемое улучшение.

Почему 512 × 1024, а не исходное разрешение? Это разрешение проекта и baseline, плюс ограничение в 8 ГБ памяти GPU. Исходное разрешение — главный путь улучшения.

Почему дашборд медленный? Он работает на 2 бесплатных CPU, без GPU и без половинной точности: примерно 1,6 с, 3,2 с и 4,1 с на изображение. В продакшене EoMT работала бы на GPU.

Воспроизводимы ли результаты? Да: три модели, переобученные с нуля в сданном ноутбуке, дают mIoU в пределах 0,002 от эталонных обучений.

Почему падает небо? Это большая однородная зона, у baseline уже 0,918. Снижение небольшое (−0,011); выигрыш трансформеров приходится на объекты.